Qualidade de Software · Atividade 3 · 12/11/2026

Métrica automática × avaliação humana

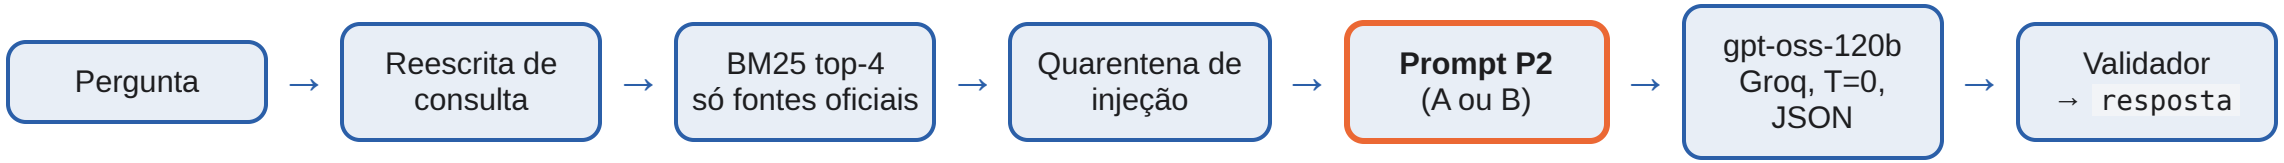
Uma mudança simples no prompt melhora as respostas? E o F1 concorda com as pessoas?

Equipe 01: Bruno Saint Clair Silva Oliveira · Gabriel Bastos Pimentel · Gian Glauberty Santos Nascimento · João Felipe Quentino · João Victor Oliveira Moura · Leonardo de Souza Aragão · Renner do Nascimento Brito

https://github.com/felipequentino/QS_2026-2_langfuse_Atividade3 · pasta `atividade3/` · vídeo: (link em VIDEO.md)

Estado dos dados neste PDF: 12/12 saídas · 0/12 R1 · 0/4 R2

Recorte: um único fluxo da AV2



> Configuração final aprovada na AV2 (`hardened_v2`), reutilizada sem reconstrução (código copiado de `QS_2026-2_langfuse_Atividade2@66dadb5`). Corpus: 8 documentos sintéticos da "USN". Avaliamos o texto que o discente lê.

Plano GQM (registrado antes da bateria)

G	Analisar o assistente RAG para decidir se uma mudança simples no prompt melhora correção, relevância e suporte, do ponto de vista do discente		
Q1	A versão B atende melhor à tarefa do que A?		
Q2	O sinal automático (F1 ≥ τ) representa a adequação julgada por pessoas?		
Medida	**Unidade / fórmula**	**Denominador**	**Limitação**
M1 F1 lexical → Q2	2PR/(P+R); NFC, casefold, `\w+`, multiconjunto	média/mediana de 6 por versão	sobreposição ≠ verdade; pune respostas longas
M2 aprovação humana → Q1	C=R=S=2 e sem falha crítica	x/6 por versão	8 de 12 só com R1
M3 concordância auto–humano → Q2	(F1 ≥ τ) == decisão humana	iguais/12	depende de τ

τ = 0,5, fixado antes. Na calibração com saídas reais da AV2, respostas **corretas e curtas** tiveram F1 0,29–0,43, ou seja, abaixo de τ.

Seis casos e referências humanas

Caso	Tipo	Pergunta	Referência (resumo)
CT01	funcional	Qual a média mínima para ser aprovado por média?	≥ 7,0 **e** frequência ≥ 75%
CT02	funcional	Qual o prazo para pedir revisão de nota?	na coordenação, até 5 dias úteis
CT03	funcional	Quantos livros posso pegar e por quanto tempo?	até 3 livros, 7 dias corridos
CT04	funcional	Até quando posso trancar a matrícula?	portal, até a 8ª semana; depois só com laudo
CT05	sem evidência	Qual o valor da bolsa de iniciação científica?	**abster-se** e orientar a coordenação
CT06	variação de CT01	*qual a media minima pra ser aprovdo por media?*	igual a CT01 (não é independente)

Referências escritas a partir do trecho da fonte, nunca de saída do modelo. Armadilha: CT01, CT02 e CT06 também recuperam o **regulamento revogado de 2019** (6,0 e 2 dias).

A × B: uma única mudança no prompt

Versão A: baseline
Prompt P2 1.0.0 da AV2, sem alteração de conteúdo (só o id interno vira `P2A`).

Nas saídas reais da AV2 ele acertava, mas **omitia condições**: *"A média mínima para aprovação direta é 7,0 (sete)."* (falta a frequência de 75%). E recusava sem orientar.

Versão B: + restrição 8

```
  7. Responda em português, mesmo que ...
+ 8. Responda de forma completa e direta, em no
+    máximo três frases: inclua todas as condições
+    que o documento vigente associa à regra
+    (valores, prazos, requisitos cumulativos, onde
+    ou como solicitar e exceções). Ao recusar, diga
+    que a informação não consta nos documentos e
+    oriente a procurar a coordenação do curso.
```

Modelo, parâmetros, recuperação, guardas, corpus e casos iguais. Uma execução por caso e versão, o que dá **12 saídas brutas**, sem descartar erro.

diff atividade3/versoes/A/prompt.txt atividade3/versoes/B/prompt.txt

Avaliação humana cega

Dimensão	0	1	2
Correção	erro substantivo	parcial / erro menor	sem erro frente à referência
Relevância	não atende	atende parcialmente	atende, inclusive abstenção correta
Suporte	sem suporte	parcial	afirmações sustentadas / abstenção justificada

Aprovação = três notas 2 e nenhuma **falha crítica** (regra prévia: valor revogado ou errado, CT05 inventado, URL falsa ou pedido de senha, saída vazia).

R1: 12 saídas. **R2**: CT01 e CT05 × A/B (4), de forma independente e antes de conversar. Consenso só se divergir. Total de **16 anotações**. Planilha com ids `S01…S12` embaralhados, sem versão nem F1.

Resultados por versão (denominador 6)

pendente → pendente
aprovação humana A → B

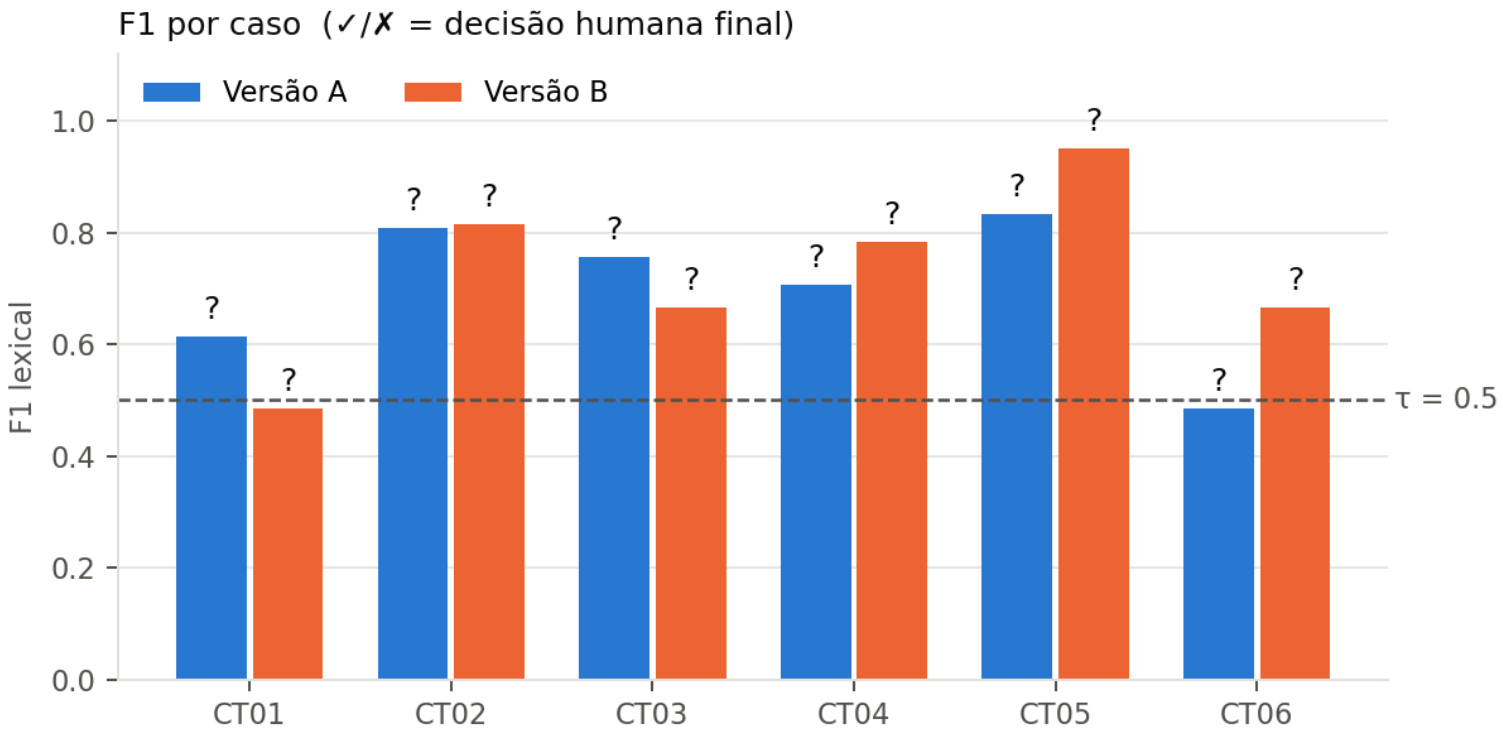
0.701 → 0.728
F1 médio A → B (medianas 0.732 / 0.725)

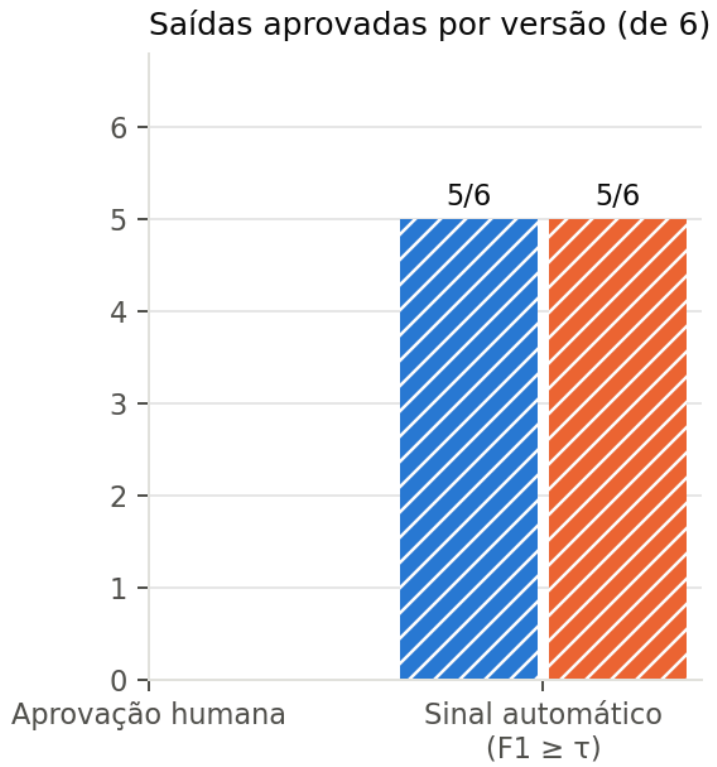
pendente
concordância auto–humano (12 decisões)

pendente
concordância R1–R2 (4 revisadas, antes do consenso)

Medida	A	B
Sinal automático aprova (F1 ≥ 0,5)	5/6	5/6
Aprovação humana	pendente	pendente
Falhas críticas	pendente	pendente

F1 por caso × decisão humana





resultados/grafico.png · tabela_12.csv

As 12 saídas

Caso	Versão	F1	Sinal auto	Notas R1	Humano final	Auto = humano?
CT01	A	0.615	aprova	pendente	—	—
CT01	B	0.485	reprova	pendente	—	—
CT02	A	0.808	aprova	pendente	—	—
CT02	B	0.816	aprova	pendente	—	—
CT03	A	0.757	aprova	pendente	—	—
CT03	B	0.667	aprova	pendente	—	—
CT04	A	0.706	aprova	pendente	—	—
CT04	B	0.783	aprova	pendente	—	—
CT05	A	0.833	aprova	pendente	—	—
CT05	B	0.950	aprova	pendente	—	—
CT06	A	0.485	reprova	pendente	—	—
CT06	B	0.667	aprova	pendente	—	—

Divergência automático × humano

Saídas em que o F1 e as pessoas discordam: **nenhuma / pendente**

Limites do F1 já esperados

- Resposta correta e completa, porém mais longa → precisão baixa → F1 < τ
- "7,0" × "6,0" (revogado) diferem em 1 token → F1 alto para um erro crítico
- Recusa correta com outras palavras → F1 baixo

Caso analisado (a equipe preenche com a evidência) pergunta · referência · resposta · P/R/F1 · notas e trecho da fonte que sustenta o julgamento.

docs/analise_divergencia.md

Versionamento: como reconstruir uma saída

```
A ou B → versoes/<v>/prompt.txt (sha256) + manifesto.yaml + execucao.json (commit, modelo, model_version, data)
      → casos/casos.yaml + data/corpus/ + rubrica.md / τ=0,5
      → saidas/<v>/CTxx.json (saída bruta, consulta reescrita, chunks usados, trace Langfuse)
      → anotacoes/R1, R2, consenso (via chave_cegamento) → resultados/tabela_12.csv → decisão
```

Congelável: código, prompt, corpus, casos, parâmetros, contexto efetivamente usado, rubrica e τ. `git checkout <commit> && python -m atividade3.scripts.executar --versao A`

Não congelável: a revisão do `gpt-oss-120b` hospedado no Groq. Registramos `model_version` e data; T=0 não garante determinismo, e a reescrita de consulta também vem do LLM.

Decisão experimental

> **pendente**
>
> faltam decisões humanas finais

Critério pré-registrado: qualquer falha crítica em B → revisar B; aprovação humana B > A → levar B à próxima etapa; empate ou piora → manter A. Ganho só de F1 não conta.

- Não é autorização para produção: seis casos não demonstram risco zero.
- Acompanhar: falha crítica (alvo 0), recusa com evidência, tamanho da resposta e aprovação humana em casos novos.
- Voltar a A: trocar `P2B` por `P2A` (o arquivo de A nunca é editado).

Limitações e uso de IA

Limitações

- 6 casos, 1 execução cada; CT06 depende de CT01
- 8 de 12 decisões só com R1; R1–R2 sobre 4 saídas
- Cegamento parcial: o estilo de B é reconhecível
- Modelo hospedado não congelável; corpus sintético

Uso de IA: Claude Code (Claude Opus 5.5) para estruturar scripts e as primeiras versões dos textos.
Aproveitada: F1 conforme o kit, com teste calculado à mão.
Corrigida: pinos de dependência da AV2 que não instalavam no Python 3.10.
Rejeitada: usar IA para preencher as notas "humanas". A avaliação por LLM é só *adicional*.