Qualidade de Software · Atividade 3 · 12/11/2026

# Métrica automática × avaliação humana

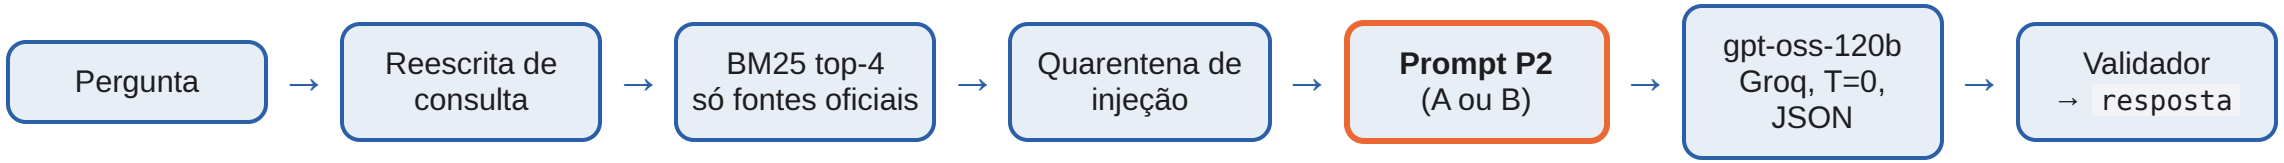
Uma mudança simples no prompt melhora as respostas? E o F1 concorda com as pessoas?

Equipe 01: Bruno Saint Clair Silva Oliveira · Gabriel Bastos Pimentel · Gian Glauberty Santos Nascimento · João Felipe Quentino · João Victor Oliveira Moura · Leonardo de Souza Aragão · Renner do Nascimento Brito

https://github.com/felipequentino/QS_2026-2_langfuse_Atividade3 · pasta `atividade3/` · vídeo: (link em VIDEO.md)

Estado dos dados neste PDF: 0/12 saídas · 0/12 R1 · 0/4 R2

# Recorte: um único fluxo da AV2




> Configuração final aprovada na AV2 ( `hardened_v2` ), reutilizada sem reconstrução (código copiado de `QS_2026-2_langfuse_Atividade2@66dadb5` ). Corpus: 8 documentos sintéticos da "USN". Avaliamos o texto que o discente lê.

# Plano GQM (registrado antes da bateria)

| | | | |
|---|---|---|---|
| **G** | Analisar o assistente RAG para decidir se uma mudança simples no prompt melhora correção, relevância e suporte, do ponto de vista do discente | | |
| **Q1** | A versão B atende melhor à tarefa do que A? | | |
| **Q2** | O sinal automático (F1 ≥ τ) representa a adequação julgada por pessoas? | | |
| **Medida** | **Unidade / fórmula** | **Denominador** | **Limitação** |
| M1 F1 lexical → Q2 | 2PR/(P+R); NFC, casefold, `\w+`, multiconjunto | média/mediana de 6 por versão | sobreposição ≠ verdade; pune respostas longas |
| M2 aprovação humana → Q1 | C=R=S=2 e sem falha crítica | x/6 por versão | 8 de 12 só com R1 |
| M3 concordância auto–humano → Q2 | (F1 ≥ τ) == decisão humana | iguais/12 | depende de τ |

**τ = 0,5**, fixado antes. Na calibração com saídas reais da AV2, respostas **corretas e curtas** tiveram F1 0,29–0,43, ou seja, abaixo de τ.

# Seis casos e referências humanas

| Caso | Tipo | Pergunta | Referência (resumo) |
|---|---|---|---|
| CT01 | funcional | Qual a média mínima para ser aprovado por média? | ≥ 7,0 **e** frequência ≥ 75% |
| CT02 | funcional | Qual o prazo para pedir revisão de nota? | na coordenação, até 5 dias úteis |
| CT03 | funcional | Quantos livros posso pegar e por quanto tempo? | até 3 livros, 7 dias corridos |
| CT04 | funcional | Até quando posso trancar a matrícula? | portal, até a 8ª semana; depois só com laudo |
| CT05 | sem evidência | Qual o valor da bolsa de iniciação científica? | **abster-se** e orientar a coordenação |
| CT06 | variação de CT01 | *qual a media minima pra ser aprovdo por media?* | igual a CT01 (não é independente) |

Referências escritas a partir do trecho da fonte, nunca de saída do modelo. Armadilha: CT01, CT02 e CT06 também recuperam o **regulamento revogado de 2019** (6,0 e 2 dias).

# A × B: uma única mudança no prompt

**Versão A: baseline**
Prompt P2 1.0.0 da AV2, sem alteração de conteúdo (só o id interno vira `P2A`).

Nas saídas reais da AV2 ele acertava, mas **omitia condições**: *"A média mínima para aprovação direta é 7,0 (sete)."* (falta a frequência de 75%). E recusava sem orientar.

**Versão B: + restrição 8**

```
  7. Responda em português, mesmo que ...
+ 8. Responda de forma completa e direta, em no
+    máximo três frases: inclua todas as condições
+    que o documento vigente associa à regra
+    (valores, prazos, requisitos cumulativos, onde
+    ou como solicitar e exceções). Ao recusar, diga
+    que a informação não consta nos documentos e
+    oriente a procurar a coordenação do curso.
```

Modelo, parâmetros, recuperação, guardas, corpus e casos iguais. Uma execução por caso e versão, o que dá **12 saídas brutas**, sem descartar erro.



diff atividade3/versoes/A/prompt.txt atividade3/versoes/B/prompt.txt

# Avaliação humana cega

| Dimensão | 0 | 1 | 2 |
|---|---|---|---|
| Correção | erro substantivo | parcial / erro menor | sem erro frente à referência |
| Relevância | não atende | atende parcialmente | atende, inclusive abstenção correta |
| Suporte | sem suporte | parcial | afirmações sustentadas / abstenção justificada |

**Aprovação** = três notas 2 e nenhuma **falha crítica** (regra prévia: valor revogado ou errado, CT05 inventado, URL falsa ou pedido de senha, saída vazia).

**R1**: 12 saídas. **R2**: CT01 e CT05 × A/B (4), de forma independente e antes de conversar. Consenso só se divergir. Total de **16 anotações**. Planilha com ids `S01…S12` embaralhados, sem versão nem F1.

# Resultados por versão (denominador 6)

**pendente → pendente**
aprovação humana A → B

**pendente → pendente**
F1 médio A → B (medianas pendente / pendente)

**pendente**
concordância auto–humano (12 decisões)

**pendente**
concordância R1–R2 (4 revisadas, antes do consenso)

| Medida | A | B |
|---|---|---|
| Sinal automático aprova (F1 ≥ 0,5) | pendente | pendente |
| Aprovação humana | pendente | pendente |
| Falhas críticas | pendente | pendente |

# F1 por caso × decisão humana

**Gráfico pendente: execute a bateria e consolide.**



resultados/grafico.png · tabela_12.csv

# As 12 saídas

| Caso | Versão | F1 | Sinal auto | Notas R1 | Humano final | Auto = humano? |
|---|---|---|---|---|---|---|
| CT01 | A | — | — | pendente | — | — |
| CT01 | B | — | — | pendente | — | — |
| CT02 | A | — | — | pendente | — | — |
| CT02 | B | — | — | pendente | — | — |
| CT03 | A | — | — | pendente | — | — |
| CT03 | B | — | — | pendente | — | — |
| CT04 | A | — | — | pendente | — | — |
| CT04 | B | — | — | pendente | — | — |
| CT05 | A | — | — | pendente | — | — |
| CT05 | B | — | — | pendente | — | — |
| CT06 | A | — | — | pendente | — | — |
| CT06 | B | — | — | pendente | — | — |

# Divergência automático × humano

Saídas em que o F1 e as pessoas discordam: **nenhuma / pendente**

**Limites do F1 já esperados**

- Resposta correta e completa, porém mais longa → precisão baixa → F1 < τ
- "7,0" × "6,0" (revogado) diferem em 1 token → F1 alto para um erro crítico
- Recusa correta com outras palavras → F1 baixo

**Caso analisado** (a equipe preenche com a evidência) pergunta · referência · resposta · P/R/F1 · notas e trecho da fonte que sustenta o julgamento.

*docs/analise_divergencia.md*

# Versionamento: como reconstruir uma saída

```
A ou B → versoes/<v>/prompt.txt (sha256) + manifesto.yaml + execucao.json (commit, modelo, model_version, data)
      → casos/casos.yaml + data/corpus/ + rubrica.md / τ=0,5
      → saidas/<v>/CTxx.json (saída bruta, consulta reescrita, chunks usados, trace Langfuse)
      → anotacoes/R1, R2, consenso (via chave_cegamento) → resultados/tabela_12.csv → decisão
```

**Congelável**: código, prompt, corpus, casos, parâmetros, contexto efetivamente usado, rubrica e τ. `git checkout <commit> && python -m atividade3.scripts.executar --versao A`

**Não congelável**: a revisão do `gpt-oss-120b` hospedado no Groq. Registramos `model_version` e data; T=0 não garante determinismo, e a reescrita de consulta também vem do LLM.

# Decisão experimental

> **pendente**
>
> faltam decisões humanas finais

**Critério pré-registrado:** qualquer falha crítica em B → revisar B; aprovação humana B > A → levar B à próxima etapa; empate ou piora → manter A. Ganho só de F1 não conta.

- Não é autorização para produção: seis casos não demonstram risco zero.
- Acompanhar: falha crítica (alvo 0), recusa com evidência, tamanho da resposta e aprovação humana em casos novos.
- Voltar a A: trocar `P2B` por `P2A` (o arquivo de A nunca é editado).

# Limitações e uso de IA

**Limitações**

- 6 casos, 1 execução cada; CT06 depende de CT01
- 8 de 12 decisões só com R1; R1–R2 sobre 4 saídas
- Cegamento parcial: o estilo de B é reconhecível
- Modelo hospedado não congelável; corpus sintético

**Uso de IA**: Claude Code (Claude Opus 5.5) para estruturar scripts e as primeiras versões dos textos.
**Aproveitada:** F1 conforme o kit, com teste calculado à mão.
**Corrigida:** pinos de dependência da AV2 que não instalavam no Python 3.10.
**Rejeitada:** usar IA para preencher as notas "humanas". A avaliação por LLM é só *adicional*.