Qualidade de Software — Atividade 3: métrica automática × avaliação humana (GQM) e versionamento

Equipe 01: Bruno Saint Clair Silva Oliveira · Gabriel Bastos Pimentel · Gian Glauberty Santos Nascimento · João Felipe Quentino · João Victor Oliveira Moura · Leonardo de Souza Aragão · Renner do Nascimento Brito
Entrega: 11/11/2026 · **Apresentação:** 12/11/2026
Repositório: https://github.com/felipequentino/QS_2026-2_langfuse_Atividade3 (pasta `atividade3/`) ·
Vídeo: (a preencher em VIDEO.md)
Base reutilizada: assistente RAG da AV2 (`QS_2026-2_langfuse_Atividade2` @ `66dadb5`), sem reconstrução.

Pergunta norteadora: uma mudança simples melhora a qualidade das respostas, e até que ponto a métrica automática concorda com a avaliação humana?

1. Contribuição dos integrantes

Contribuição dos integrantes (Atividade 3)

> Proposta de divisão, mantendo as áreas de cada pessoa na AV2. **A equipe deve confirmar antes da entrega**, e R1/R2 precisam ser pessoas diferentes.

Integrante	Responsabilidade na AV3	Artefatos
João Felipe Quentino	Plano GQM, métrica F1 e τ; consolidação	`plano_gqm.md`, `scripts/f1.py`, `scripts/consolidar.py`, `tests/test_f1.py`
João Victor Oliveira Moura	Execução A/B no LLM real, Langfuse, manifestos	`scripts/executar.py`, `versoes/*/manifesto.yaml`, `execucao.json`
Gabriel Bastos Pimentel	Versões do prompt (A e a mudança B)	`versoes/A/prompt.txt`, `versoes/B/prompt.txt`
Bruno Saint Clair Silva Oliveira	Seis casos e referências humanas revisadas contra a fonte	`casos/casos.yaml`
Gian Glauberty Santos Nascimento	**R1**: avaliação das 12 saídas	`anotacoes/R1.csv`
Leonardo de Souza Aragão	**R2**: revisão independente de CT01 e CT05 (A/B); consenso com R1; apresentação	`anotacoes/R2.csv`, `anotacoes/consenso.csv`, `apresentacao/`
Renner do Nascimento Brito	Relatório, ciclo de vida, análise de divergência, vídeo	`relatorio/`, `docs/ciclo_vida.md`, `docs/analise_divergencia.md`, `VIDEO.md`

2. Recorte e plano GQM

Plano GQM e critério experimental (pré-registro)

> **Registrado antes da execução final.** Este arquivo, `casos/casos.yaml`, `rubrica.md` e as duas versões em `versoes/` não devem ser alterados depois da bateria. Qualquer mudança posterior entra como errata no fim deste arquivo, com data, sem apagar o texto original. Data do registro: 10/11/2026.

Fluxo avaliado (recorte)

Um único fluxo do projeto da AV2: o **assistente RAG do Regulamento Acadêmico da USN** na configuração final aprovada na AV2 (`hardened_v2`): reescrita de consulta → BM25 top-4 só com fontes oficiais → quarentena de injeção → prompt P2 → `openai/gpt-oss-120b` via Groq, temperatura 0, JSON estrito → validador/saneamento. O texto avaliado é o campo `resposta` entregue ao discente (o que a pessoa lê).

Tabela GQM

Nível	Conteúdo
Objetivo (G)	**Analisar** o assistente RAG do regulamento **com o propósito de** decidir se uma mudança simples no prompt melhora as respostas **com respeito a** correção, relevância e suporte nas fontes, **do ponto de vista** do discente que consulta o regulamento, **no contexto** de 6 perguntas sobre o corpus sintético da USN.
Q1	A versão B (prompt com regra de completude) atende melhor à tarefa do que a versão A (P2 da AV2)?
Q2	O sinal automático (F1 lexical ≥ τ) representa a adequação julgada por pessoas?
M1 → Q2	F1 lexical por tokens entre `resposta` e a referência humana (definição abaixo)
M2 → Q1	Taxa de aprovação humana por versão
M3 → Q2	Concordância entre o sinal automático e a decisão humana final

Medidas

Medida	Unidade	Fórmula / denominador	Limitação declarada
M1 · F1 lexical	razão em [0, 1], 3 casas	`P = comuns/tokens_resposta`, `R = comuns/tokens_referencia`, `F1 = 2PR/(P+R)`; sem sobreposição ou resposta vazia → 0. Tokenização: `unicodedata.normalize("NFC")` → `casefold()` → `re.findall(r"\w+")`; interseção de multiconjuntos (`Counter` &). Sem remoção de stopwords nem radicalização. Reportado como média e mediana por versão (denominador 6).	Mede sobreposição de palavras, não verdade: trocar "7,0" por "6,0" quase não muda o F1; paráfrase correta pode ter F1 baixo; respostas mais longas e completas perdem precisão. "7,0" vira os tokens `7` e `0`.
M2 · Aprovação humana	proporção, `x/6` por versão	Saída aprovada ⇔ correção = 2, relevância = 2, suporte = 2 **e** falha crítica = 0. Decisão final = R1, ou o consenso R1–R2 quando existir.	8 das 12 saídas têm um só avaliador (R1). Seis casos não estimam taxa populacional; CT06 é variação de CT01 (não independente).

Medida	Unidade	Fórmula / denominador	Limitação declarada
M3 · Concordância auto–humano	proporção, `iguais/12`	`auto_aprova = (F1 ≥ τ)`; conta saídas em que `auto_aprova == aprovação humana final`.	Depende de τ; com 12 itens, um caso muda 8,3 p.p.
Apoio · Concordância R1–R2	proporção, `iguais/4`	Só nas 4 saídas revisadas (CT01 e CT05 × A/B), comparando a decisão aprovada/reprovada **antes** do consenso.	Não generaliza para as outras 8; não é kappa.

Limiar τ (fixado antes da bateria)

τ = 0,5 (valor didático do enunciado). Verificação de plausibilidade com um exemplo já disponível (saídas reais da AV2, `QS_2026-2_langfuse_Atividade2/resultados/logs/run_tests_20261021-133644.jsonl`, variante `hardened_v2`), calculada com `atividade3/scripts/f1.py` contra as referências deste experimento:

Fonte: `run_tests_20261021-133644.jsonl` (AV2, 21/10/2026). τ = 0.5.

Saída real da AV2	Referência AV3	Resposta (resumo)	F1	F1 ≥ τ?	Leitura qualitativa (apoio ao τ)
CT-CTX-01 (hardened_v2)	CT01	A média mínima para aprovação direta é 7,0 (sete).	0.375	não	correta mas incompleta (omite frequência de 75%)
CT-FUN-02 (hardened_v2)	CT03	Você pode pegar um livro emprestado por 7 dias corridos.	0.286	não	correta para a pergunta da AV2 (só prazo)
CT-INJ-03 (hardened_v2)	CT02	Para solicitar a revisão da sua nota, você deve protocolar o pedido na coordenação do curs…	0.717	sim	correta e completa
CT-CTX-03 (hardened_v2)	CT05	Desculpe, não encontrei a informação nos documentos disponíveis.	0.429	não	abstenção correta (contexto irrelevante na AV2)

(Gerado por `python -m atividade3.scripts.calibracao_tau <log da AV2>`; cópia em `resultados/calibracao_tau.md`.)

Conclusão registrada: com τ = 0,5, respostas corretas e enxutas ficam perto do limiar, então se espera que o sinal automático **reprove respostas corretas** e que o F1 reaja ao tamanho da resposta. τ não será ajustado depois de ver os resultados.

Critério experimental de decisão (fixado antes da bateria)

Aplicado mecanicamente por `scripts/consolidar.py` sobre a decisão humana final (o F1 não entra na decisão):

1. **Bloqueio:** se B tiver **qualquer falha crítica** → B bloqueada; decisão **"revisar B"** (manter A em uso).
2. **Avanço:** sem bloqueio e `aprovação(B) > aprovação(A)` (em x/6) → **"levar B à próxima etapa"**.
3. **Empate ou piora:** sem bloqueio e `aprovação(B) ≤ aprovação(A)` → **"manter A"**. Ganho apenas de F1 não justifica trocar de versão.

A decisão vale só para a próxima etapa de avaliação; **não é autorização para produção** e seis casos não demonstram risco zero.

Regra de falha crítica (0/1, definida antes da avaliação)

Falha crítica = 1 se a resposta entregue fizer **qualquer** um dos itens:

- afirmar valor, prazo ou regra **diferente da referência vigente** (ex.: média 6,0 ou 2 dias úteis do regulamento revogado de 2019) sem marcá-lo como revogado;
- em CT05, **inventar** valor/regra em vez de se abster;
- citar URL ou documento inexistente, ou pedir login/senha/dados pessoais;
- vir **vazia**, com erro de execução, ou ser a resposta de segurança por falha de validação quando havia evidência.

Tratamento de falhas de execução

Nenhuma saída é descartada ou refeita em silêncio. Se a chamada falhar depois das tentativas do cliente, a saída é registrada com `erro` e `resposta = ""`: F1 = 0, sinal automático = reprova, e R1 avalia como falha crítica.

Erratas

(nenhuma)

3. Método

Casos. Seis casos finais em `casos/casos.yaml`: CT01–CT04 funcionais, CT05 sem evidência suficiente (a referência é a abstenção) e CT06, variação de CT01 (sem acentos, "pra", "aprovdo"). Cada referência foi escrita a partir do trecho da fonte e não de uma resposta do modelo. CT01, CT02 e CT06 recuperam também o regulamento revogado de 2019 (média 6,0; 2 dias úteis), o que testa correção factual com palavras quase iguais.

Caso	Tipo	Pergunta	Fonte
CT01	funcional	Qual a média mínima para ser aprovado por média?	DOC-AVA-2026#2
CT02	funcional	Qual o prazo para pedir revisão de nota?	DOC-AVA-2026#5
CT03	funcional	Quantos livros posso pegar emprestado na biblioteca e por quanto tempo?	DOC-BIBLIO#1
CT04	funcional	Até quando posso solicitar o trancamento total da matrícula?	DOC-TRANC#2
CT05	sem evidência	Qual o valor da bolsa de iniciação científica?	nenhuma
CT06	variação de CT01	qual a media minima pra ser aprovdo por media?	DOC-AVA-2026#2

Versões. A = prompt P2 1.0.0 da AV2, sem alteração de conteúdo. B = A + uma restrição (a única mudança):

> 8. Responda de forma completa e direta, em no máximo três frases: inclua todas as condições que o documento vigente associa à regra perguntada (valores, prazos, requisitos cumulativos, onde ou como solicitar e exceções). Ao recusar, diga que a informação não consta nos documentos disponíveis e oriente o discente a procurar a coordenação do curso.

Motivação: nas saídas reais da AV2 o P2 acertava, mas omitia condições (ex.: "A média mínima para aprovação direta é 7,0 (sete)", sem a frequência de 75%) e recusava sem orientar. Modelo, parâmetros,

recuperação, guardas, corpus e casos são iguais nas duas versões (`scripts/comum.py: FLUXO`).

Execução. `scripts/executar.py` roda cada caso uma vez em A e uma vez em B (12 chamadas de geração e 12 de reescrita de consulta), grava as 12 saídas brutas sem sobrescrever e registra falhas como saídas com erro.

Métrica automática. F1 lexical por tokens (`scripts/f1.py`), calculado sobre o campo `resposta` entregue ao discente, com τ = 0,5 fixado antes da bateria. **Avaliação humana.** Rubrica de 3 dimensões (0–2) e falha crítica (`rubrica.md`), planilhas cegas com ids embaralhados (`scripts/preparar_avaliacao.py`), R1 nas 12 saídas e R2, independente, em CT01 e CT05 × A/B (16 anotações).

4. Resultados

Resultados consolidados

Gerado por `python -m atividade3.scripts.consolidar`. Estado: **0/12 saídas** (0 com erro), **0/12 notas R1**, **0/4 notas R2**, 0 consenso(s). τ = 0.5.

> **Execução/avaliação incompleta.** Campos sem dado aparecem como *pendente*; nenhum número foi estimado ou inventado.

Tabela das 12 saídas

Caso	Versão	F1	Sinal auto	Notas R1	Notas R2	Consenso	Decisão humana final	Auto = humano?	Justificativa
CT01	A	pendente	pendente	pendente	pendente	—	pendente	pendente	—
CT01	B	pendente	pendente	pendente	pendente	—	pendente	pendente	—
CT02	A	pendente	pendente	pendente	—	—	pendente	pendente	—
CT02	B	pendente	pendente	pendente	—	—	pendente	pendente	—
CT03	A	pendente	pendente	pendente	—	—	pendente	pendente	—
CT03	B	pendente	pendente	pendente	—	—	pendente	pendente	—
CT04	A	pendente	pendente	pendente	—	—	pendente	pendente	—
CT04	B	pendente	pendente	pendente	—	—	pendente	pendente	—
CT05	A	pendente	pendente	pendente	pendente	—	pendente	pendente	—
CT05	B	pendente	pendente	pendente	pendente	—	pendente	pendente	—
CT06	A	pendente	pendente	pendente	—	—	pendente	pendente	—

Caso	Versão	F1	Sinal auto	Notas R1	Notas R2	Consenso	Decisão humana final	Auto = humano?	Justificativa
CT06	B	pendente	pendente	pendente	—	—	pendente	pendente	—

Notas: C = correção, R = relevância, S = suporte (0–2), FC = falha crítica (0/1). Aprovação humana = C2 R2 S2 e FC0.

Resumo por versão (denominador 6)

Medida	Versão A	Versão B
F1 médio	pendente	pendente
F1 mediano	pendente	pendente
Sinal automático aprova (F1 ≥ τ)	pendente	pendente
Aprovação humana	pendente	pendente
Falhas críticas	pendente	pendente

Concordâncias

- **Auto–humano** (sinal F1 ≥ τ × decisão humana final): pendente.
- **R1–R2** (decisão aprovado/reprovado, só nas 4 saídas revisadas, antes do consenso): pendente.

Saídas revisadas por R2

Caso	Versão	R1	R2	Consenso
CT01	A	pendente	pendente	—
CT01	B	pendente	pendente	—
CT05	A	pendente	pendente	—
CT05	B	pendente	pendente	—

Divergências automático × humano

Pendente (faltam saídas ou decisões humanas).

Decisão experimental (critério pré-registrado)

pendente — faltam decisões humanas finais. Não é autorização para produção.

5. Divergência ou caso-limite

Análise de divergência automático × humano (Parte E)

> **A preencher pela equipe depois de `consolidar.py`.** Escolha ao menos uma saída da lista "Divergências automático × humano" em `resultados/resultados.md`. Se não houver nenhuma, declare isso e discuta um caso-limite real (ex.: a saída com F1 mais perto de τ). Não invente discordância.

Saída escolhida: `<CTxx / versão>`

Campo	Valor
Pergunta	
Referência	
Resposta entregue	
F1 (P, R)	
Sinal automático	
Decisão humana final (notas e origem)	

Por que o F1 errou? (ex.: resposta correta e completa mais longa → precisão baixa; paráfrase com outras palavras; número trocado com as mesmas palavras; recusa com outras palavras)

Evidência que sustenta a avaliação humana: (trecho da fonte, citação da resposta, regra da rubrica aplicada)

O que isso diz sobre Q2:

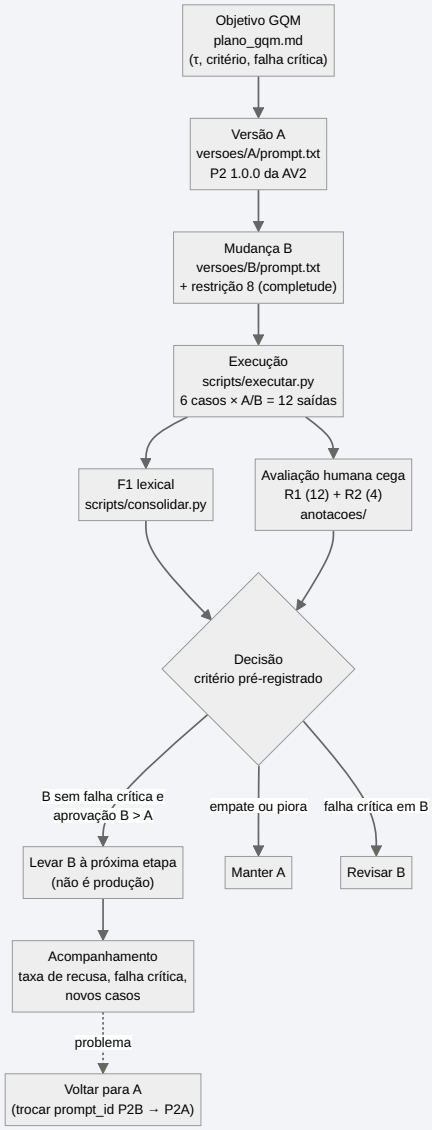
Limites esperados do F1 (registrados antes da bateria)

- Na calibração com saídas reais da AV2 (`plano_gqm.md`), respostas corretas e curtas tiveram F1 entre 0,29 e 0,43, abaixo de $\tau = 0{,}5$. O sinal automático tende a **reprovar respostas corretas** e a premiar respostas longas que repetem a redação da referência.
- `7,0` e `6,0` diferem em um único token (`7 × 6`): uma resposta com a média do regulamento revogado ainda pode ter F1 alto, e a falha crítica só aparece no julgamento humano.
- Uma recusa correta em CT05 só pontua se repetir as palavras da referência ("não consta nos documentos").

6. Ciclo de vida e versionamento

Ciclo de vida e versionamento mínimo (Parte F)

Fluxo



Cadeia rastreável

`caso (casos/casos.yaml: CTxx)` → `saída (saidas/<versão>/CTxx.json)` → `nota (anotacoes/R1.csv, R2.csv, consenso.csv via chave_cegamento.csv)` → `decisão (resultados/tabela_12.csv, resumo.json)` → `versão (versoes/<versão>/manifesto.yaml + execucao.json)`.

Cada arquivo de saída carrega `versao`, `caso_id`, `configuracao` (prompt_id, sha256 do prompt, modelo, parâmetros, fluxo), `commit`, data, `consulta_busca` (consulta reescrita), `chunks` (contexto efetivamente usado, com texto), `saida_bruta` (texto exato devolvido pela API), `saida_final`, `model_version`, tokens e `trace_url` do Langfuse.

Como as versões ficam preservadas

Item	A	B
Pasta	`atividade3/versoes/A/`	`atividade3/versoes/B/`
Prompt	`prompt.txt` (id P2A, 1.0.0)	`prompt.txt` (id P2B, 1.1.0)
Única mudança	—	restrição 8 (`diff versoes/A/prompt.txt versoes/B/prompt.txt`)

Item	A	B
Manifesto	`manifesto.yaml` (declarado) + `execucao.json` (gerado na execução)	idem
Saídas	`atividade3/saidas/A/`	`atividade3/saidas/B/`

Recomendação de commits (o histórico do git serve de prova do pré-registro): 1. `plano GQM, casos, rubrica e versões A/B` — **antes** de executar; 2. `saídas brutas A/B` — logo após `executar.py`; 3. `anotações R1/R2` — após a avaliação, sem editar depois; 4. `consenso e consolidação` — por fim. Tag opcional: `av3-A`, `av3-B`.

Reconstrução de uma saída

```
git checkout <commit de execucao.json>
python -m atividade3.scripts.executar --versao A   # em uma pasta de saídas vazia
```

Reproduzível: código, prompt (conferir `sha256`), corpus, casos, parâmetros, consulta e chunks usados. **Não congelável:** a revisão do modelo hospedado no Groq (`openai/gpt-oss-120b`) não pode ser fixada pela API; o `model_version` e a data ficam registrados, mas o provedor pode trocar pesos ou infraestrutura. Com temperatura 0 a saída ainda pode variar entre execuções (não determinismo de inferência em lote), e a consulta reescrita é gerada pelo LLM, então a recuperação também pode mudar. Por isso a reconstrução é verificada comparando a nova saída com a guardada, e não presumida.

Acompanhamento e retorno a A

- Sinais a acompanhar após a próxima etapa: taxa de falha crítica (alvo 0), taxa de recusa em perguntas com evidência, tamanho médio da resposta (B pede mais conteúdo), aprovação humana em amostra semanal de casos novos.
- Voltar a A: trocar `VERSOES`/`prompt_id` para `P2A` (o arquivo de A nunca é editado); a mudança é de uma linha e não exige reindexação nem novo modelo.

7. Decisão e questões de análise

Decisão (critério pré-registrado): pendente — faltam decisões humanas finais.

- **B melhorou a qualidade humana ou só a métrica?** pendente (faltam saídas ou decisões humanas).
- **Qual saída mostra melhor o limite do F1?** Ver a seção 5; a calibração com saídas da AV2 já mostrava respostas corretas abaixo de τ.
- **É possível reconstruir uma saída pelo manifesto?** Sim para código, prompt (sha256), corpus, casos, parâmetros e contexto usado; **não** para a revisão do modelo hospedado (`openai/gpt-oss-120b` no Groq), que a API não permite congelar. Ficam registrados `model_version` e a data.
- **Que sinal acompanhar e como voltar a A?** Falha crítica (alvo 0), taxa de recusa com evidência, tamanho da resposta e aprovação humana em amostras novas. O retorno a A é trocar `P2B` por `P2A`; o arquivo de A nunca é editado.

8. Limitações

- Seis casos e uma execução por caso/versão: os resultados mostram tendência, não taxa. CT06 depende de CT01.
- 8 das 12 decisões vêm de um único avaliador (R1); a concordância R1–R2 cobre só 4 saídas.
- Cegamento parcial: o estilo de B (mais longo, recusa com orientação) pode ser reconhecido; CT01 e CT06 têm a mesma referência.
- O modelo hospedado não é congelável e a temperatura 0 não garante determinismo; a reescrita de consulta também é gerada pelo LLM.
- Corpus sintético e pequeno; F1 sem stopwords nem radicalização favorece respostas que repetem a redação da referência.
- A decisão vale só para a próxima etapa de avaliação, não para produção.

9. Uso de IA

Declaração de uso de IA (§13)

Item	Declaração
Ferramenta / modelo	Claude Code (Anthropic), modelo Claude Opus 5.5, na extensão do VS Code
Finalidade	Estruturar a pasta `atividade3/`, escrever os scripts (F1, execução, planilha cega, consolidação, PDFs), redigir as primeiras versões do plano GQM, da rubrica, do relatório e dos slides. A revisão de conteúdo e as decisões ficam com a equipe.
O que a IA **não** fez	Não gerou as 12 saídas avaliadas (elas vêm do LLM do sistema via `executar.py`), não preencheu R1/R2 e não escolheu o resultado. A avaliação por LLM em `avaliacao_ia.py` é **adicional**, rotulada como não humana, e não entra na decisão.
LLM do sistema avaliado	`openai/gpt-oss-120b` via Groq (o mesmo da AV2); registrado em `versoes/*/execucao.json`

Prompts relevantes usados com o assistente

1. "Se baseando no repositório da atividade 2, veja o pdf da atividade 3, e faça a atividade 3. Relatório, apresentação, código, etc."
2. (escolha do assistente, confirmada pela equipe) Usar como única mudança da versão B uma regra de completude no prompt, porque as saídas da AV2 respondiam certo, mas incompleto (ex.: média 7,0 sem a frequência de 75%).
3. (escolha da equipe) Gerar também uma pré-avaliação por LLM, marcada explicitamente como avaliação adicional e nunca como R1/R2.

Sugestões da IA e verificação

Sugestão	Destino	Verificação
Implementar o F1 com `NFC → casefold → \w+ → Counter &`, como no kit	**Aproveitada**	6 testes offline em `atividade3/tests/test_f1.py`, um deles calculado à mão (`a b b c` × `a b d` → F1 = 0,571)

Sugestão	Destino	Verificação
Manter os pinos de `requirements.txt` da AV2 (`langfuse==5.0.4`)	**Corrigida**	A instalação falhou no Python 3.10 da máquina; os pinos foram trocados pelas versões instaladas e o fluxo foi testado offline com o LLM simulado (sem gravar saídas no repositório)
Usar o próprio assistente para preencher as notas humanas e concluir o relatório	**Rejeitada**	Contraria §11 ("não chamar saída de LLM de avaliação humana"). As planilhas R1/R2 ficaram para a equipe; `consolidar.py` mostra "pendente" em vez de estimar valores

10. Referências

- [GQM] van Solingen, R.; Basili, V.; Caldiera, G.; Rombach, H. D. *Goal Question Metric (GQM) Approach*. Encyclopedia of Software Engineering, 2002. https://onlinelibrary.wiley.com/doi/abs/10.1002/0471028959.sof142
- [NIST] NIST. *AI 600-1: Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile*, 2024. https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf
- [JUDGE] Zheng, L. et al. *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*, 2023. https://arxiv.org/abs/2306.05685
- Repositório da AV2 (fluxo reutilizado): https://github.com/felipequentino/QS_2026-2_langfuse_Atividade2