QUALIDADE DE SOFTWARE — ATIVIDADE 3

Escopo: métricas automáticas versus avaliação humana (GQM)
Ciclo de vida e versionamento de sistemas generativos

Informação	Definição
Modalidade	Trabalho em equipe; manter as equipes de Qualidade de Software
Lançamento	05/11/2026
Entrega do relatório e repositório	11/11/2026
Apresentação	12/11/2026
Tempo por equipe	10–12 minutos de apresentação e 3–5 minutos para perguntas
Carga mínima	6 casos × 2 versões = 12 respostas; 12 avaliações principais + 4 segundas revisões = 16 anotações

1. Contexto e pergunta norteadora

A equipe deverá avaliar um único fluxo do projeto já utilizado nas atividades anteriores. O foco é executar um experimento, comparar um sinal automático com julgamento humano e registrar a mudança de versão. Não é necessário reconstruir a aplicação.

Pergunta norteadora: uma mudança simples melhora a qualidade das respostas, e até que ponto a métrica automática concorda com a avaliação humana?

2. Objetivos de aprendizagem

- Aplicar GQM para escolher medidas a partir de uma finalidade concreta.
- Comparar duas versões do mesmo fluxo com os mesmos seis casos.
- Identificar diferenças entre similaridade lexical, adequação factual, relevância e suporte.
- Produzir uma decisão experimental apoiada nas evidências e em artefatos versionados.

3. Escopo

São exigidos um objetivo GQM, duas perguntas, seis casos finais, duas versões e uma execução por caso/versão.

Reutilizar modelo/provedor, projeto e fontes já disponíveis. Não são obrigatórios treinamento, GPU, API paga, nova base vetorial, contêineres, CI/CD em nuvem ou LLM como juiz. Scripts fornecidos podem ser usados ou substituídos por planilha/código equivalente. Priorizar execução, tabela e interpretação, sem repetir toda a Atividade 2.

4. Parte A — Plano GQM em uma tabela

Definir um objetivo, duas perguntas e três medidas simples: F1 lexical automático, taxa de aprovação humana e concordância entre o sinal automático e a decisão humana final. Para cada medida, declarar unidade, fórmula/denominador e limitação. O plano deve ser registrado antes do teste final. [GQM]

Exemplo de objetivo	Pergunta e medida
Melhorar respostas com fontes do fluxo escolhido	Q1: a versão B atende melhor à tarefa? Taxa de aprovação humana.
Mesmo objetivo, outra perspectiva	Q2: o sinal automático representa adequação? F1 lexical e concordância auto–humano.

5. Parte B — Seis casos, duas versões e 12 saídas

Casos	Tipo	Preparação
CT01–CT04	4 funcionais	Perguntas curtas com fonte e resposta esperada conhecidas
CT05	1 sem evidência suficiente	Referência descreve abstenção ou declaração de limite esperada
CT06	1 variação de CT01	Paráfrase ou erro de digitação que preserve a intenção

- Preparar a pergunta, referência curta revisada por pessoa e identificação da fonte/trecho. Não usar outra resposta do modelo como única verdade de referência.
- Versão A: baseline. Versão B: mudar apenas um fator principal, preferencialmente o prompt. Manter modelo, casos e condições restantes comparáveis.
- Executar cada caso uma vez em A e uma vez em B. Guardar 12 saídas brutas com versão, caso, configuração e fonte/contexto efetivamente usados.
- Não descartar erro nem fabricar resposta. Uma saída vazia/falha precisa ser registrada e tratada pelo critério definido. CT06 é relacionado a CT01, não uma observação independente.

6. Parte C — Uma métrica automática simples

Calcular F1 lexical por tokens entre o texto gerado e a referência humana. Fixar normalização e tokenização; o kit usa NFC, casefold, tokens de palavras e interseção de multiconjuntos. Não é obrigatório produzir JSON ou mudar o formato nativo da aplicação.

```
P_tokens = tokens_em_comum / tokens_da_resposta
R_tokens = tokens_em_comum / tokens_da_referencia
F1_lexical = 2 * P_tokens * R_tokens / (P_tokens + R_tokens)
# Sem sobreposicao ou com resposta vazia: F1 = 0.
# Referencia sem tokens: corrigir caso ou declarar politica; nao inventar score.
```

Definir antes da bateria um limiar tau para o sinal “automático aprova se F1 >= tau”. A equipe pode usar 0,5 como valor didático ou justificar outro, sem ajustá-lo após ver o resultado final. Não há novo conjunto de calibração obrigatório; um exemplo já disponível pode apoiar a escolha.

7. Parte D — Avaliação humana

Dimensão	0	1	2
Correção	Erro substantivo	Parcial/erro menor	Sem erro identificado na referência
Relevância	Não atende	Atende parcialmente	Atende, inclusive abstenção correta
Suporte	Sem suporte	Suporte parcial	Afirmações sustentadas ou abstenção justificada

Um avaliador principal (R1) aplica a rubrica às 12 saídas e registra evidência/justificativa breve. Registrar ainda falha crítica (0/1) com regra prévia. Aprovação humana: três notas 2 e nenhuma falha crítica.

Um segundo avaliador (R2) revisa apenas CT01 e CT05 nas duas versões: quatro saídas adicionais. Nas quatro, avaliar independentemente antes de conversar. Se houver divergência, registrar consenso justificado sem apagar R1/R2. Nas outras oito, a nota de R1 é a decisão operacional, com essa limitação declarada.

Ocultar versão e scores durante a avaliação quando viável. Registrar limitações do cegamento. Não há obrigação de avaliar duas vezes todas as saídas, contratar juiz ou medir kappa. [NIST], [JUDGE]

8. Parte E — Comparar e interpretar, sem estatística complexa

- Montar uma tabela das 12 saídas: caso/versão, F1, sinal automático, notas humanas, decisão humana final e justificativa.
- Apresentar por versão F1 médio ou mediano e aprovação humana, sempre com denominador 6. Calcular concordância auto–humano sobre as 12 decisões: iguais/12.
- Informar concordância R1–R2 somente nas quatro saídas revisadas: iguais/4, antes do consenso. Não usar 12 ou 16 como denominador dessa comparação.
- Analisar ao menos uma divergência automática–humana. Se não houver, declarar isso e discutir um caso-limite real, sem inventar discordância.
- Incluir uma tabela consolidada e um gráfico simples ou visualização equivalente. Matriz de confusão, correlação e testes estatísticos são opcionais.

Exemplo de limitação: trocar “10/11” por “11/11” mantém muitas palavras, mas pode mudar a resposta factual. Uma paráfrase correta pode ter F1 baixo. O exercício não exige que B seja melhor: uma conclusão fundamentada de manter A é válida.

9. Parte F — Ciclo de vida e versionamento mínimo

Desenhar um fluxo pequeno: objetivo -> versão A -> mudança B -> execução -> avaliação -> decisão e acompanhamento. Pode ser uma figura simples no relatório; não é necessário implantar pipeline de produção.

- Preservar A e B em pastas ou commits identificáveis. Registrar a única mudança principal. Tags de release e ferramentas de registro de modelos são opcionais.
- Usar um manifesto curto por versão: código/commit, prompt, modelo/revisão e parâmetros, fonte/contexto, casos/referências, rubrica/limiar e resultados. Pode ser um único JSON/YAML/Markdown.
- Registrar data e limitações quando API/modelo não permitir congelar revisão. Não exigir hash de todo arquivo, infraestrutura nova ou automação completa.
- Manter a cadeia caso -> saída -> nota -> decisão -> versão. O dado original e as avaliações anteriores não devem ser sobrescritos silenciosamente.

```
A ou B -> commit/pasta + prompt + modelo/configuracao
    -> casos/fontes + rubrica/tau + saidas + avaliacao
    -> decisao e justificativa
```

10. Decisão experimental e questões de análise

Definir antes do teste um critério simples de avanço e uma condição de bloqueio por falha crítica. Ao final, decidir manter A, levar B à próxima etapa ou revisar. Essa decisão não é autorização para produção; seis casos não demonstram risco zero.

- A mudança B melhorou a qualidade humana ou apenas a métrica automática?
- Qual saída mostra melhor o limite do F1 e qual evidência sustenta a avaliação?
- É possível reconstruir uma saída usando o manifesto? Qual parte não foi congelável?
- Que sinal acompanhar depois e como voltar a A se surgir um problema?

11. Segurança e integridade

Usar dados públicos, sintéticos ou autorizados. Não publicar credenciais, prompts pessoais ou documentos sigilosos. Não chamar saída de LLM de “avaliação humana”.

12. Entregáveis — somente o essencial

- Relatório técnico objetivo em PDF: contribuição dos integrantes; recorte/GQM; método; tabela/gráfico; divergência ou caso-limite; versionamento/diagrama; decisão; limitações e referências. Não é exigido texto longo nem repetição do histórico do projeto.
- Repositório do projeto de Qualidade de Software com pasta atividade3/, README e referências recuperáveis das versões A/B.
- Arquivos das seis perguntas/referências, 12 saídas brutas, tabela automática e 16 anotações humanas (12 R1 + 4 R2), com consenso apenas quando necessário.
- Manifesto curto por versão, plano GQM e critério experimental de decisão. Código fornecido pode ser reutilizado com atribuição; planilhas equivalentes são aceitas.
- Slides e vídeo com participação identificável de todos; URL no README, relatório e VIDEO.md/video.txt. No Classroom, enviar link do vídeo, não o arquivo.

13. Apresentação e uso de IA

Apresentação em 12/11/2026: 10–12 minutos por equipe e 3–5 minutos para perguntas. Todos devem participar. Mostrar GQM, mudança A/B, resultado, uma divergência/caso-limite e como a versão é reconstruída. O escopo reduzido não altera esses tempos.

Declarar ferramenta/modelo usados como apoio, finalidade, até três prompts relevantes e uma sugestão aproveitada/corrigida/rejeitada com sua verificação. Não é obrigatório usar LLM-as-a-judge; se usado, identificar como avaliação adicional, nunca substituto das anotações humanas.

14. Cronograma confirmado

Data	Marco
05/11/2026	Lançamento da atividade
11/11/2026	Entrega do relatório, repositório/versão, evidências, slides e link do vídeo
12/11/2026	Apresentações: 10–12 minutos, com 3–5 minutos para perguntas

15. Checklist

Um objetivo GQM e duas perguntas; seis casos; versões A/B; 12 respostas; F1 e aprovação humana; 12 anotações R1 e quatro R2; denominadores corretos; consenso quando preciso; uma análise de divergência ou caso-limite; tabela/visualização; manifestos e diagrama; decisão e limites; contribuições, vídeo e IA declarados.

16. Referências de partida

[GQM] van Solingen; Basili; Caldiera; Rombach. Goal Question Metric Approach (2002). https://onlinelibrary.wiley.com/doi/abs/10.1002/0471028959.sof142

[NIST] NIST. AI 600-1: Generative Artificial Intelligence Profile (2024). https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf

[JUDGE] Zheng et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena (2023). https://arxiv.org/abs/2306.05685